

IDEA5_HDBrain_MASTER

HDBrain — 新加坡组屋(HDB)ML估值与购房负担能力顾问：专属主文档

上游文档：BRAINSTORMING_MASTER.md (Idea 5 当选)

团队：4 人 | 自定 DDL：10 天 (2026-07-13 → 2026-07-23)

本文档定位：Idea 5 的唯一工作主文档——概念展开、调研结果、工作流程、后续所有该 idea 的进展都记录在此。

目录 (骨架)

- 产品故事 (User Story)
- 功能构想 (Feature Ideation)
- 前端 / 后端架构想象 (Architecture Sketch)
- 技术细节展开：ML / LLM / Web 各做什么
- 广泛调研结果 (Research Findings)
- 10 天四人工作流程 (Workstreams & Plan)
- 差异化定位与评分对照 (Positioning)
- 风险清单与开放问题 (Risks & Open Questions)
- 工作日志 (Work Log)

1. 产品故事 (User Story)

主线故事：Wei Ling 和 Marcus 的买房之旅

Wei Ling (27 岁，市场营销专员，月薪 S\$4,800) 和未婚夫 Marcus (29 岁，物流主管，月薪 S\$5,500) 打算明年结婚。BTO 摇号两次失败后，他们决定转向转售组屋 (HDB resale flat) 市场。周五晚上，两人坐在咖啡馆里打开了 **HDBrain**。

第一幕：我们到底买得起什么？(负担能力, Affordability)

Wei Ling 在「Affordability Explorer」里输入两人的月收入、现有存款 (现金 S\$60k + CPF OA 合计 S\$110k)、每月车贷 S\$600。系统瞬间按 MSR 30% (Mortgage Servicing Ratio, 月供收入比)、TDSR 55% (Total Debt Servicing Ratio, 总债务收入比)、LTV 75% (Loan-to-Value, 贷款价值比) 规则算出：**最高可负担房价约 S\$68 万** (HDB 贷款路径) 或 S\$72 万 (银行贷款路径，但需多付 5% 现金)。新加坡地图立即变色——**买得起的镇区亮绿灯**：Woodlands、Sengkang、Punggol 的 4-room 随便挑；Queenstown、Bishan 的 4-room 大面积灰掉，但同镇 3-room 还亮着。两人第一次对“预算 vs 地段”的取舍有了直观的全景图。

第二幕：这套房到底值多少？(ML 估值)

中介带他们看了一套 Sengkang 的 4-room，卖家开价 S\$62 万。Marcus 把地址、楼层区间 (10-12 层)、面积 93m²、剩余租期 74 年输入「AI Valuation」。模型 (XGBoost, 训练于 90 万+ 条官方成交记录) 给出估值 **S\$58.6 万, 90% 置信区间 [S\$56.1 万, S\$61.2 万]**——开价高出估值 5.8%。页面下方的 SHAP 瀑布图解释了每一分钱：+S\$3.2 万来自“距离 MRT 380 米”，+S\$1.8 万来自中高楼层，**-S\$2.4 万来自剩余租期只剩 74 年**。旁边自动列出同小区近 6 个月 8 笔真实成交对照。两人拿着这张“估值卡”跟卖家砍到了 S\$59.5 万。

第三幕：现在买还是再等等？(市场脉搏)

Wei Ling 心里还打鼓：房价会不会跌？她点开「Market Pulse」：Sengkang 4-room 价格指数过去 12 个月 +4.2%，模型对下半季度的方向判断是“温和上行”，且该镇当前“估值热度分”处于全岛中位——不算过热。LLM 生成的一段人话总结写道：“以你们的预算，该镇当前溢价水平合理；若再等 6 个月，按近期趋势可能多付约 S\$1-2 万，但你们的 CPF 也会增长约 S\$8k，紧迫性中等。”

第四幕：结果

两周后他们以 S\$59.3 万签约——比开价省下 S\$2.7 万，月供 S\$1,780 (收入的 17.3%，远低于 30% 红线)，Wei Ling 把 HDBrain 的估值报告 PDF 存进了婚礼筹备文件夹。

次要用户画像 (一并覆盖，展示时可提)

用户	场景	用到的功能
卖家 Auntie Tan	想知道自家 Toa Payoh 老三房挂牌价该定多少	AI 估值 + 同类成交对照
换房家庭	卖 4-room 换 5-room，算“卖旧买新”的资金缺口	估值 × 2 + 负担能力引擎
政策研究者/学生	想看“剩余租期衰减对价格的影响” (99 年地契问题)	市场分析页的租期-价格曲线

2. 功能构想 (Feature Ideation)

分为 P0（核心，必须有，直接对应评分项） / P1（强烈建议） / P2（时间富余再做）。

P0 — 核心闭环（缺一不可）

- 1. **AI Valuation 估值器**：输入镇区/楼型/楼层/面积/剩余租期（→ 自动地理编码补齐 MRT 距离等特征）→ 输出估值 + 置信区间 + SHAP 逐特征解释瀑布图 + 近期同类真实成交对照表。**这是 ML 主线的门面。**
- 2. **Affordability Explorer 负担能力地图**：输入收入/存款/CPF/现有债务 → 规则引擎（MSR/TDSR/LTV/印花税 BSD）算出最高可负担价 → 地图上按镇区×楼型高亮“买得起/买不起”，点击镇区看该预算下的可选楼型和预计月供。**这是产品创新的门面（估值的反向查询）。**
- 3. **Model Arena 模型对比页**：Linear Regression / Ridge / Random Forest / XGBoost /（可选 LightGBM、简单 NN）的 RMSE / MAE / R² / MAPE 横向对比表 + 残差分析图 + 特征重要性对比。**这是 60% 评分项的直接证据陈列室——别的组藏在 notebook 里，我们把它做成产品页面。**

P1 — 强烈建议

- 4. **Market Pulse 市场脉搏**：分镇区价格指数曲线（可按楼型筛选）、同比涨幅热力图、“估值热度分”（当前成交价 vs 模型估值的镇区级平均溢价——负数=可能低估的镇）。
- 5. **Lease Decay Lab 租期衰减实验室**：固定其他特征，只滑动“剩余租期”滑块，实时看估值曲线——把新加坡人最关心的 99 年地契问题做成可交互的教学工具（展示/poster 的高光点）。
- 6. **LLM 报告生成**：一键把估值结果 + SHAP + 负担能力结论合成一段自然语言“购房顾问报告”（可下载）。单次 API 调用，成本可忽略。
- 7. **Responsible AI 页**：模型局限性声明（不能替代持牌估价师）、数据截止时间、置信区间的正确解读、按镇区/楼型分组的误差公平性审计表。**5% 送分项 + 加深专业印象。**

P2 — 时间富余再做

- 8. 租金估值（data.gov.sg 也有 HDB 出租登记数据）→ “买 vs 租”对比计算器。
- 9. BTO vs Resale 对比器（等 BTO 的机会成本估算）。
- 10. 聚类页：K-means 把 26 个镇按价格行为聚成“价格带”，展示无监督学习。
- 11. 历史回测：用 2023 年前数据训练、预测 2024-2025 成交，展示模型的时间外推能力（这个其实建议升 P1，见 §4.1 评估设计）。

3. 前端 / 后端架构想象 (Architecture Sketch)

3.1 总体形态：两条备选路线

	路线 A：纯 Streamlit（推荐）	路线 B：React + FastAPI 全栈
结构	Streamlit 多页应用，模型以 pickle/joblib 加载	React(Vite)+ECharts/Mapbox 前端 ⇄ FastAPI 后端 ⇄ 模型服务
工期	2-3 人日	6-8 人日
评分	Dashboard usability 10% 完全够	同样是 10%，无额外分
结论	默认走 A ；4 人里前端手快、且 P0 提前完成时可升级 B	备选

课程官方也把 Streamlit 列为推荐路径（Lecture 6），评分表里应用可用性只占 10%——工程炫技的边际收益为零，**把省下的时间全部砸进模型与评估。**

3.2 后端（数据与模型层）设想

1	
2	离线管道（notebook / scripts，一次性+定期重跑）
3	data.gov.sg CSV（1990-now，~90万条）
4	→ 清洗（楼层区间中点化、租期解析成月、面积异常值）
5	→ OneMap API 地理编码（block 地址 → 经纬度，带缓存）
6	→ 特征工厂：距最近MRT/CBD距离、镇区one-hot、
7	成交年月、楼龄、storey、flat_model 等
8	→ enriched_dataset.parquet
9	→ 训练脚本：LR/Ridge/RF/XGBoost + GridSearchCV
10	+ 时间切分验证 → models/*.joblib + metrics.json
11	→ SHAP explainer 预计算
12	
13	在线层（Streamlit 进程内直接调用）
14	· 估值服务：特征拼装 → model.predict → 区间 → SHAP
15	· 负担能力引擎：纯规则函数（MSR/TDSR/LTV/BSD/月供公式）
16	· 对照检索：pandas 按镇/楼型/面积近邻查询成交记录

17 | · LLM 客户端：一个薄封装，失败时优雅降级为模板文本 |
18 | _____ |

关键设计取舍：

- **地理编码离线做、结果落盘缓存**（全岛 HDB block 仅约 1 万个唯一地址，一次跑完永久复用）——在线请求零外部依赖，演示时不怕断网/限流。
- 数据集 enriched 后以 parquet 存储，Streamlit 直接读，不需要数据库（"simple web application"的字面许可）。
- 模型全部预训练落盘，页面加载 <1s。

3.3 前端（页面结构）设想

1	侧边栏导航	
2	Home	一句话价值主张 + 三入口
3	AI Valuation	表单 → 估值卡（数字+区间）→ SHAP瀑布图 → 可比成交表
4	Affordability	收入表单 → 可负担上限卡 → 镇区×楼型热力图（pydeck/plotly）
5	Market Pulse	镇区指数曲线、热度热力图、租期衰减滑块实验室
6	Model Arena	模型对比表、残差图、特征重要性、时间外推回测
7	Responsible AI	局限性、公平性审计、数据来源声明

视觉锚点（poster/demo 记忆点）：**新加坡地图热力图**（Affordability）+ **SHAP 瀑布图**（Valuation）+ **租期衰减曲线**（Lease Lab）。

4. 技术细节展开

4.1 ML 要做什么（项目的 60% 主线）

任务定义：监督回归——给定房屋特征，预测转售成交价 `resale_price`。

特征工程（评分 20% 的对应物，要做出层次感）

| 层 | 特征 | 说明 |

| --- | --- | --- |

| 原始 | town, flat_type, flat_model, floor_area_sqm, storey_range, lease_commence_date, month | 直接来自官方数据 |

| 衍生 | remaining_lease_months（解析）、storey_mid（区间中点）、flat_age、成交年/月（周期性编码） | 展示清洗功力 |

| **地理（我们的差异化）** | 距最近 MRT 站距离、距 CBD(Raffles Place)距离、1km 内小学数量（可选）、经纬度 | OneMap API 免费地理编码 |

| 市场 | 该镇过去 6 个月同楼型中位价（滞后特征，防泄漏：只用成交月之前的数据） | 展示时间序列意识 |

模型阵容与对比实验（评分 20%+20% 的对应物）

1. Baseline 0: 镇区×楼型分组中位价（"中介经验法"，必须有，用于回答"ML 到底带来多少提升"）。
2. Linear Regression → Ridge/Lasso（正则化对比）。
3. Random Forest。
4. XGBoost（预期冠军，文献里 $R^2 \approx 0.96-0.98$ 、 $MAE \approx S\$1.5-2$ 万）。
5. 可选: LightGBM、简单 MLP（覆盖"深度学习也试过"）。

评估设计（这是拉开差距的地方，别的组常见错误是随机切分）

- **时间切分为主**：train ≤ 2023-12, test = 2024-01 至今——模拟真实部署（"用历史预测未来"）；同时报告随机切分结果，**对比两者差异本身就是一个发现**（随机切分会高估性能，因为同小区同期成交泄漏）。
- 指标: RMSE、MAE、 R^2 、**MAPE 与中位百分比误差**（行业口径——SRX X-Value 公布的就是"中位误差 2.8%"，我们直接跟行业标杆对表！）。
- 分组误差分析: 按镇区/楼型/价格段的 MAE 表 → 同时喂给 Responsible AI 公平性讨论。
- 不确定性: Quantile Regression（XGBoost 的 quantile 目标或 GBR quantile loss）给出 5%-95% 置信区间，并做区间覆盖率校验。
- 消融实验: 无地理特征 vs 有地理特征——定量证明"我们加的 MRT 距离值多少钱"。

无监督（可选加分）：K-means 镇区聚类（按价格水平+增速+波动），Silhouette 选 k，正好用上 Lecture 4。

负担能力引擎（非 ML，纯金融规则，但是金融相关性 20% 的核心素材）

- $MSR \leq 30\%$ （HDB/EC 适用）、 $TDSR \leq 55\%$ 、LTV 上限 75%（2024-08 起 HDB 贷款从 80% 下调）、月供按等额本息公式（HDB 贷款利率 2.6% vs 银行贷款约 3-4%，双路径对比）、BSD 印花税分级、CPF OA 可用额。
- 反向求解: 给定收入/存款 → 最高可负担房价 → 与各镇区各楼型的模型估值分布求交 → 地图着色。

4.2 LLM 要做什么 (严格辅助位, 符合我们的定调)

用途	调用时机	成本控制	降级方案
估值报告生成: 把估值+SHAP top5+负担能力结论 → 一段人话顾问报告	用户点击"生成报告"按钮时	每次 1 call, 输入 <1k tokens	无 API key 时回退到模板字符串拼接
Market Pulse 摘要: 镇区指数数据 → 每周市场点评	离线预生成, 存静态文本	每周 26 镇 ×1 call, 可一次性生成	同上
(可选 P2) RAG 政策问答: 喂 HDB 官网的购房规则页面, 回答"BTO 和 resale 的 grant 差别"	用户提问时	呼应 Lecture 5 的 RAG 主题	砍掉不影响主线

原则写进代码: **LLM 挂了/没额度, 产品所有核心功能照常运行**。这句话本身放进 Responsible AI 页和 presentation, 就是加分陈述。

4.3 Web 要做什么

- Streamlit 多页应用 (见 §3.3) , `st.cache_data` / `st.cache_resource` 缓存数据与模型。
- 地图: `pydeck` (Streamlit 原生支持) 或 `plotly choropleth` ; 需要新加坡 planning area 的 GeoJSON (data.gov.sg 有 Master Plan 边界数据) 。
- 图表: plotly (交互式 SHAP 瀑布、残差图、指数曲线) 。
- 部署: Streamlit Community Cloud (免费、给 TA/评委一个可点击链接——交付物清单里明确要 dashboard link) 。

5. 广泛调研结果 (Research Findings)

调研日期: 2026-07-13。结论先行: **数据侧完美 (官方、免费、量大、字段全), 学术与开源侧"预测价格"已被做过多次——所以我们的创新必须落在"估值+负担能力反向查询+不确定性+公平性"的产品与方法组合上, 而非预测本身。**

5.1 数据来源 (全部免费, 已验证存在)

数据	来源	内容	用途
HDB Resale Flat Prices	data.gov.sg (官方开放数据门户)	1990 至今全部转售成交, ~90 万条: month, town, flat_type, block, street_name, storey_range, floor_area_sqm, flat_model, lease_commence_date, remaining_lease, resale_price; 分 5 个 CSV 按年代拆分, 持续更新	核心训练数据
OneMap API	onemap.gov.sg (SLA 官方)	免费地理编码/逆编码/路径规划, 无需付费 (搜索端点甚至无需注册) ; 实操教程	block 地址 → 经纬度 → MRT/CBD 距离特征
MRT 站点坐标	data.gov.sg / OneMap / 社区整理 CSV	全部车站经纬度 (含在建线路)	距离特征
HDB Property Information	data.gov.sg	每栋 block 的总层数、单位数、建成年	特征补充
Master Plan Planning Area 边界 GeoJSON	data.gov.sg (URA)	镇区多边形	地图热力图
HDB Renting Out of Flats	data.gov.sg	出租登记数据	P2 租金估值
政策参数	MAS MSR/TDSR 官方解释 、 MoneySense 官方购房负担指南	MSR 30% / TDSR 55% / LTV 75% (HDB 贷款, 2024-08 起) / HDB 贷款利率 2.6% / 银行贷款 5% 现金首付规则	负担能力引擎的规则依据 (引用官方来源, 报告显专业)
参考数据准备教程	Towards Data Science 数据准备实战 、 新加坡开放城市数据指南 (Urban Analytics Lab, NUS)	踩坑指南	加速 Day 1-2

5.2 市面成品 (竞品/标杆——证明真实需求存在, 也是我们对标的对象)

产品	定位	关键事实	对我们的意义
SRX X-Value (srx.com.sg/xvalue-pricing)	新加坡最早 (2014) 的自动估值模型 (AVM, Automated Valuation Model)	自称 98% 准确率; Resale HDB 中位百分比误差 2.8% , 公寓 2.1%; 基于 ML 分析可比成交	行业金标准 。我们的评估直接用同口径 (中位百分比误差) 对表: "学生项目 vs 行业标杆差多少" ——极好的 presentation 叙事
99.co Property Value Tool (99.co/singapore/property-value-tool/hdb)	由 SRX X-Value 驱动 (同属 99 Group)	提供买/卖/租/再融资估值报告	学习其结果呈现方式 (估值卡 + 可比成交)
PropertyGuru 估值工具	竞品 AVM	按同区同面积历史成交给出高于/低于均值判断	功能参照
工具横评 (Ohmyhome) 、 Seedly 横评	第三方评测	各工具估值差异可达数万新元	佐证"估值不确定性"叙事 → 支撑我们的置信区间功能
市场空白	—	竞品全都是"给房估价"; 没有一家做"给人估房" (输入你的财务状况 → 反向告诉你哪里); MoneySense/银行的负担能力计算器只给一个数字, 不连地图不连估值模型	这就是我们的创新缺口: Valuation × Affordability 的闭环产品

5.3 学术界与开源项目

类别	条目	要点
开源 (NUS 课程作品!)	grrrrnt/hdb-resale-price-prediction (NUS CS3244 项目)	多 ML 模型横评的先例—— 说明本校课程语境认可该选题 ; 也提醒我们必须做得比"裸预测"更多
开源 (最接近我们的)	teyang-lau/HDB_Resale_Prices	2015-2019 数据, $R^2=0.96$, $MAE \approx \$2$ 万, 且已做 Streamlit 部署—— 架构直接可参考 , 同时是我们超越的基线 (更多数据、地理特征、区间估计、负担引擎)
开源	hengbl/HDB-Resale-Price-Prediction 、 JackFongNew/Singapore-HDB-Resale-Price-Prediction 、 changjulian17/resale_HDB	特征工程与建模思路参考池
技术博客 (性能锚点)	UpLevel 项目报告 : GBR $RMSE \approx \$17.8k$, $R^2=98.7\%$ vs 线性回归 $RMSE \approx \$36k$, $R^2=94.5\%$; Desmond Quek 2025 用 SHAP 解释 HDB 价格	给了我们明确的性能预期区间 : 树模型 $R^2>0.96$ 是"及格线", $MAE < \$2$ 万可达
学术方向关键词 (写报告引用)	hedonic pricing model (特征价格模型, 房地产估值经典理论框架)、automated valuation model (AVM)、lease decay effect (新加坡 99 年地契租期衰减, SMU/NUS 有多篇实证研究)	报告/短论文的理论包装: 我们做的本质是 "ML-based hedonic AVM + affordability constraint mapping"

5.4 调研总结论 (一句话)

数据完美、选题被验证、竞品与文献给出清晰的性能锚点 (中位误差 ~3%、 $R^2 \approx 0.96$ 、 $MAE \approx \$2$ 万); **"预测价格"没有创新分, 创新分在: ① Affordability 反向查询闭环 (市场空白) ② 置信区间+时间外推的诚实评估 ③ SHAP 可解释 + 公平性审计 ④ 与行业标杆 SRX 同口径对表的叙事。**

6. 10 天四人工作流程

DDL: 2026-07-23。按**工作流 (workstream)** 划分而非按天排期; 每个 workstream 有负责人 (Owner)、产出物 (Deliverable) 和验收标准 (DoD, Definition of Done)。四人代号 A/B/C/D (组内自行认领)。

Workstream 1: 数据管道 (Owner: A; 前 30% 时间最重)

- 下载 5 个年代段 CSV, 合并、schema 对齐 (老数据无 remaining_lease 字段, 需从 lease_commence_date 推算)。
- 清洗: storey_range → 中点数值; remaining_lease 字符串 → 月数; 异常值检查 (面积/价格极端值)。
- OneMap 地理编码脚本 (带本地缓存 + 限速重试), 产出 `block→(lat,lng)` 映射表 (~1 万唯一地址)。
- 特征工厂: MRT 距离、CBD 距离、镇区滞后中位价 (注意时间防泄漏)。
- **DoD**: `enriched_dataset.parquet` 生成, 附一页数据字典; 抽查 20 个地址的地理编码正确。

Workstream 2: 建模与评估 (Owner: B, C 协作; 全程最重, 60% 分数所在)

- Baseline (分组中位价) → LR/Ridge → RF → XGBoost, 统一的训练/评估脚手架 (同一切分、同一指标函数, 保证公平比较)。
- 时间切分 vs 随机切分双轨评估; GridSearchCV/TimeSeriesSplit 调参。
- Quantile 模型输出置信区间 + 覆盖率校验。
- SHAP explainer 预计算与序列化。
- 消融实验 (±地理特征)、分组误差表 (镇/楼型/价格段)。
- **DoD**: `metrics.json` + 模型文件落盘; XGBoost 时间外推 MAPE 中位数 ≤5% (对标 SRX 2.8%, 学生项目 5% 内即可讲好故事); 每个对比实验有一张可直接进 slides 的图。

Workstream 3: 负担能力引擎 + 业务规则 (Owner: C)

- 实现 MSR/TDSR/LTV/月供/BSD 印花税/CPF 规则的纯函数库 (HDB 贷款 vs 银行贷款双路径), 每条规则注明官方出处 (MAS/MoneySense)。
- 反向求解器: 财务状况 → 最高可负担价 → 与镇区×楼型估值分布求交。
- 单元测试: 用 MoneySense 官方计算器的算例做对拍验证。
- **DoD**: 至少 5 个手工算例与官方计算器结果一致 (±1%)。

Workstream 4: Web 应用 (Owner: D; 中后段发力)

- Streamlit 骨架六页 (见 §3.3) 先用假数据搭出来 (不等模型), 随后逐页接真数据。
- 地图热力图 (planning area GeoJSON + pydeck/plotly)、SHAP 瀑布图、租期滑块实验室。
- LLM 报告生成薄封装 (含无 key 降级)。
- 部署到 Streamlit Community Cloud。
- **DoD**: 外网可访问链接; 一次完整的"故事线走查" (按 §1 的 Wei Ling 剧本从头点到尾无报错)。

Workstream 5: 文档与展示 (全员, Owner: A 牵头; 最后 30% 时间)

- README/报告 (问题陈述、数据、方法、评估、局限、Responsible AI——直接按交付物清单的小节写)。
- Poster (视觉锚点: 地图热力图 + SHAP 瀑布 + 模型对比表 + "vs SRX 2.8%"对比图)。
- Slides + demo 演练 (按 Wei Ling 故事讲, 3 分钟版和 8 分钟版各一)。
- (可选, 冲分) ACM 格式 4 页短论文: "An Interpretable ML-based AVM with Affordability Mapping for Singapore Public Housing"。
- **DoD**: 所有交付物齐 + 至少 2 次全组彩排。

里程碑 (Milestone, 不排日程只设检查点)

检查点	状态标准	建议不晚于
M1 数据就绪	enriched parquet 可用, EDA 完成	Day 3
M2 模型冠军产生	全部模型跑完对比, XGBoost 调优完成	Day 6
M3 端到端可点	Web 六页全部接真数据, 云端可访问	Day 8
M4 冻结与打磨	功能冻结, 只修 bug + 做文档/poster/彩排	Day 9-10

并行原则

- W1 与 W4 (假数据骨架)、W3 从 Day 1 即可三线并行; W2 在 M1 后火力全开 (B+C 双人); C 在 W3 完成后转入 W2 做评估实验。
- 每晚 15 分钟站会 (线上即可): 昨天/今天/阻塞。所有进展记入本文档 §9 工作日志。

7. 差异化定位与评分对照

一句话定位 (写进 proposal 的第一段):

HDBrain is an interpretable, ML-based automated valuation model (AVM) for Singapore public housing, extended with an affordability-mapping engine that inverts the valuation question — from "what is this flat worth?" to "which flats can / afford?" — grounded in official MAS lending rules (MSR/TDSR/LTV).

评分项	我们的对应弹药
Financial relevance & problem framing 20%	普通人最大金融决策; MAS 官方规则引擎; hedonic AVM 理论框架
Data prep & feature engineering 20%	90 万条官方数据 + OneMap 地理特征 + 防泄漏滞后特征 + 数据字典

评分项	我们的对应弹药
Model correctness 20%	Baseline→线性→树→集成的完整阶梯 + 调参 + quantile 区间
Evaluation & benchmark 20%	时间外推评估、消融实验、分组误差、 与行业标杆 SRX 2.8% 同口径对表
Dashboard usability 10%	六页 Streamlit + 地图 + 云端链接 + 故事线走查
Responsible AI 5%	专门页面：非持牌估价声明、公平性审计、LLM 降级设计、数据时效
Presentation 5%	Wei Ling 故事线 demo + 三大视觉锚点
Innovative Idea	Affordability 反向查询 = 已验证的市场空白 (\$5.2)

关于新加坡 vs 中国：确定新加坡。理由：① 官方数据质量碾压（中国二手房无同级公开成交明细）；② 教授/评委的本地共鸣；③ MAS 规则公开明确可引用；④ OneMap 免费。中国方向仅在 limitations 里提一句“框架可迁移”。

8. 风险清单与开放问题

风险	等级	缓解
OneMap API 限速导致地理编码慢	中	唯一地址仅 ~1 万个；带缓存分批跑，Day 1 就启动
地图 GeoJSON 与 HDB town 命名对不上 (planning area ≠ HDB town)	中	提前做映射表；对不上就退化为按镇散点/气泡图
随机切分成绩好看、时间切分成绩下滑	低	这本身就是我们要讲的发现，诚实报告即可
Streamlit Cloud 部署内存限制 (90 万行数据)	中	线上只带聚合后数据 + 模型文件；明细查询预生成索引
规则引擎参数过时 (LTV 等政策变动)	低	全部参数集中一个 config 文件 + 标注来源与查证日期

开放问题（待组内/TA 确认）：

- ☐ 问 TA：项目是否需要“预测未来价格走势”成分，还是横截面估值即可？（影响是否加一个简单的镇区指数 ARIMA 预测模块——加了正好覆盖 Lecture 4 的统计模型）
- ☐ 组内认领 A/B/C/D 角色
- ☐ 是否冲 ACM 短文（建议：是，W2 的实验设计本来就是按论文标准做的）
- ☐ LLM 用哪家 API（预算 <\$5，任何便宜模型都够）

9. 工作日志 (Work Log)

日期	事项	产出
2026-07-13	Idea 5 当选；完成概念展开（故事/功能/架构/技术细节）；完成四轮网络调研（学术、竞品、开源、数据源、政策规则）；制定 10 天四 workstream 计划	本文档 v1
2026-07-13	搭建并跑通最小可运行 Pipeline (MVP)，验证 Workstream 1（数据管道）与 Workstream 2（建模评估）的核心思路可行	<code>Project/HDBrain_MVP_Pipeline/</code> ，详见下方 \$10

(后续每次工作在此追加)

10. MVP 工作说明 (2026-07-13)

这一节讲清楚：这次做了什么、为什么这么做、结果说明了什么、和正式版差距在哪、下一步该干嘛。
对应产出：`Project/HDBrain_MVP_Pipeline/`（独立文件夹，含 `README.md`、`scripts/`、`data/`、`outputs/`）

10.1 这次任务的定位

任务要求“最小可运行 pipeline，不需要把前端后端做出来”。所以这次**只打通 ML 主线**（\$4.1 里设计的“数据 → 特征工程 → 多模型对比 → 评估”这条 60% 分值所在的链路），完全不碰 Streamlit 页面、LLM 接口、负担能力引擎这些属于 Workstream 3/4 的内容。目的是尽早验证两件最有风险的事：**真实数据到底能不能拿到手**，以及**我们设计的评估方法（时间切分、消融实验）在真实数据上到底跑不跑得****出有意义的数字**。这两件事一旦有问题，越早发现成本越低——这也是为什么把它排在 10 天计划最前面做。

10.2 做了什么，按顺序讲

第一步：找数据。原计划直连 data.gov.sg 官方 API 下载，但实测发现该站点有 Cloudflare 反爬保护，本机网络环境下用 `curl` 直连返回 403（不是数据不存在，是访问被拦截，学校网络或浏览器环境大概率没有这个问题）。于是转向一个我们在前期调研阶段（\$5.3）就已经发现并记录过的开源项目 teyang-lau/HDB_Resale_Prices——它的仓库里完整镜像了 data.gov.sg 的官方原始 CSV（内容是官方数据，只是访问路径换成了 GitHub），还额外带了 MRT 站点坐标表，正好省掉了自己整理 MRT 坐标的功夫。最终下载到了 **117,527 条 2015-01 至 2020-09 的真实 HDB 转售成交记录**。这不是模拟数据，是真实官方交易记录，只是时间跨度受限于这个镜像仓库最后同步的时间点（2020-09）——正式开发阶段需要换回直连 data.gov.sg 拿到最新数据。

第二步：清洗和特征工程（`scripts/01_build_dataset.py`）。把两个年代段的 CSV 合并、统一 `remaining_lease` 字段格式（2017 年后官方数据写作“61 years 04 months”这种字符串，2015-2016 年数据是纯数字年份，得先统一解析成月数）、把“10 TO 12”这种楼层区间转换成数值中点、算出楼龄。这些是基础清洗。真正体现设计功力的是两块：一是地理特征——用经纬度算每笔交易到最近 MRT 站、到 CBD (Raffles Place) 的距离；二是“防泄漏”的市场滞后特征——每笔交易所在镇区和楼型的“过去 6 个月历史中位价”，这里特意用了 `shift(1)` 确保只用**成交月之前**的历史数据，不会用未来信息“偷看”答案（这是很多学生项目容易踩的坑，我们在文档设计阶段就写明了要避免）。

关于地理坐标的简化，这里要说清楚：正式设计要求用 OneMap API 对每一栋楼（block）做精确地理编码。但这次 MVP 没有去申请/调用 OneMap API（一是为了让 pipeline 在任何网络环境下都能独立跑通、不依赖外部 API 的稳定性，二是控制这次任务的范围），改用了 **26 个 HDB 镇区的中心点坐标**做近似替代——同一个镇区的所有交易共享同一个坐标。这个简化是**故意且明确标注**的：它足够支撑我们验证“地理距离特征到底有没有用”这个方法论问题（结果证明有用，见下），但不足以支撑“精确到每栋楼的定价差异”这个正式版要做的事。README 和本节都把这一点写清楚了，避免后续被误认为是精确坐标。

第三步：多模型训练与评估（`scripts/02_train_and_evaluate.py`）。五个模型放在同一套评估脚手架里公平对比：Baseline（镇区×楼型分组中位价，代表“中介经验法”）、Linear Regression、Ridge、Random Forest、GBRT（Gradient Boosting，这里作为 XGBoost 的替代，原因见下）。做了三组实验：① 随机切分 vs 时间切分，看两者结果差多少；② 有无地理特征的消融实验，量化地理特征的价值；③ 特征重要性 + 置换重要性（permutation importance），看模型到底在依赖什么信息做判断。

第四步：出图（`scripts/03_make_plots.py`）。生成了模型对比条形图（带 SRX X-Value 行业标杆参考线）和特征重要性图，存在 `outputs/` 里，可以直接用在后续的 slides/poster 里。

10.3 中间踩的一个坑：environment 被搞坏了，已经修复

按原计划要装 `xgboost` 和 `shap`（正式设计里用 SHAP 做可解释性瀑布图）。`pip install shap` 把本机全局 numpy 从 1.26 升级到了 2.2，而这台机器上的 pandas/streamlit 等一批库是针对 numpy 1.x 编译的，升级后当场导致 `import pandas` 全面报错——不只是这个项目的问題，是**整个 Python 环境**都受影响。发现后立刻用 `pip install "numpy<2"` 把版本压回 1.26.4，卸载了引发冲突的 `shap`、`xgboost`、`cvxpy`，验证 numpy/pandas/sklearn/matplotlib/streamlit 全部恢复正常后才继续往下做。

因为这个原因，MVP 里没有真的用 `xgboost`（用 sklearn 自带的 `GradientBoostingRegressor` 代替，效果同源、原理相近，正式开发时换回 `XGBRegressor` 只需要改一行）、没有用 `shap`（用 sklearn 自带的 `permutation_importance` 加 RandomForest 内置特征重要性代替）。这是这次 MVP 和正式设计之间**最大的一处技术性偏差**，记录在这里防止大家看到 README 里“GBRT_XGBoost_proxy”这种命名感到困惑——这是有意为之的替代方案，不是疏漏。

10.4 结果说明了什么

跑出来的核心数字（详见 `outputs/model_comparison_summary.csv` 和 README）：

- Random Forest 是这次 MVP 里表现最好的模型：**时间切分下 $R^2=0.900$ ， $MAE \approx \$32,060$ ，中位数绝对百分比误差 5.44%。这和我们在调研阶段（\$5.3）从其他开源项目和论文里查到的性能锚点（ $R^2 \approx 0.96-0.98$ ）比略低，主要因为：① 地理坐标是镇区级近似而非精确坐标；② 用的是更严格的时间外推评估，而不是大部分参考项目用的随机切分。
- 随机切分确实会让模型“显得更好”：**同一个 Random Forest，随机切分给出 $R^2=0.939$ ，时间切分只有 0.900。这正好验证了我们在文档设计阶段（\$4.1）就预判的“评估陷阱”——同小区同时期的成交存在信息泄漏，随机切分会高估真实的样本外表现。这个对比本身就是一个值得写进报告的发现，而不是失败。
- 地理特征确实有用：**去掉 MRT/CBD 距离特征后，GBRT 的 R^2 从 0.9044 降到 0.8909。即使只是粗糙的镇区级近似坐标也能带来可测量的提升，这为“正式版换上 OneMap 精确坐标后效果会更好”这个假设提供了初步支撑证据。
- 和行业标杆的差距是可解释、可缩小的：**SRX X-Value 官方公布的 HDB 中位误差是 2.8%，我们目前是 5.4%-6.1%。差距主要来自坐标精度和数据新鲜度（截至 2020-09），而不是方法论缺陷——这个“差距可归因”的叙事本身对报告和 presentation 是有利的。

10.5 和正式设计（\$3、\$4）的差距清单

项目	MVP 现状	正式设计要求	影响
地理坐标	26 个镇区中心点近似	OneMap API 精确到每栋 block	精度上限，是提升空间最大的一项
数据时间范围	2015-01 ~ 2020-09 (GitHub 镜像)	data.gov.sg 最新数据（至今）	缺了近 5 年市场数据，尤其疫情后的价格结构变化
树模型	sklearn GBRT	XGBoost（需重新处理 numpy 版本冲突，建议用虚拟环境隔离）	预期性能相近，XGBoost 一般略优且训练更快

项目	MVP 现状	正式设计要求	影响
可解释性	Permutation Importance + RF 内置重要性	SHAP 逐样本瀑布图	MVP 只能看"整体"重要性，看不到"单笔交易"级别的解释
不确定性量化	无	Quantile Regression 置信区间 + 覆盖率校验	正式版才有"90% 置信区间"这个产品卖点
调参	默认/手调参数	GridSearchCV + TimeSeriesSplit	当前数字有进一步优化空间
前端/负担能力引擎/LLM	完全没做	Workstream 3/4 的全部内容	本次任务范围明确排除，不是遗漏

10.6 下一步建议

1. 组内确认后，把这次踩过的 numpy/xgboost/shap 环境冲突问题记下来——**正式开发建议用虚拟环境（venv/conda）隔离**，不要在这台机器的全局 Python 环境里继续装包，避免再次影响其他项目。
2. 优先在学校网络或浏览器环境下测试能否直连 data.gov.sg 官方 API（如果可以，就不需要再依赖 GitHub 镜像，能拿到最新数据）。
3. 申请 OneMap API（免费、据调研不需要注册即可用搜索接口），把地理编码从"镇区近似"升级到"block 精确"，这是下一步性价比最高的改进点。
4. 这次的评估脚手架（`02_train_and_evaluate.py`）设计成了可直接扩展的结构——加新模型、加新实验，都可以在现有函数基础上加，不需要重写。